BOGOTÁ DATAJAM EDICIÓN 5 · THE DATA SQUAD · EQUIPO #16

El miedo que no baja

Por qué solo dos de ocho hipótesis se sostienen, y la propuesta final: un sistema unificado de registro y cruce de datos de seguridad

Brandow Brusly León Rodríguez, Samuel Esteban Riveros Cubides y Rafael Estiven Londoño Camacho, estudiantes de Ciencia de Datos. Complementa el informe técnico (secciones 6.9 y 7.2). Todas las cifras salen del repositorio del proyecto.

1. Por qué solo se sostienen dos de ocho hipótesis

Las ocho hipótesis se escribieron con su criterio de decisión antes de ver los resultados. Por eso un rechazo es un resultado y no un error: dice qué explicación descartar y hacia dónde mirar después. Tres de las ocho son creencias frecuentes del debate público (alumbrado, vías, luz e internet) y las probamos a propósito, porque son las que más orientan la inversión.

El marcador

Lo que se esperaba	Prueba	Resultado	Veredicto
La serie de hurto es comparable en el tiempo (H0)	Razón capa SCJ ÷ SIEDCO por año	2,28 a 2,55 veces hasta 2022; 1,00 desde 2023	No se sostiene
El delito registrado explica el miedo (H1)	Logit con wild bootstrap; prueba de contexto en ML	p wild = 0,92; AUC 0,726 sin él y 0,724 con él	No se sostiene
Peor alumbrado, más hurto	Spearman, 19 localidades, BH	Luminarias por km ρ = +0,48 (al revés); alumbrado malo ρ = −0,02	No se sostiene
Vías en mal estado, más hurto	Spearman con el PCI del IDU	ρ = −0,35; p BH = 0,34	No se sostiene
Más luz o internet, menos violencia contra ellas	Spearman con la tasa SIVIM	Iluminación ρ = +0,02; conectividad ρ = −0,28	No se sostiene
Donde sobra miedo, falta denuncia (H2)	Spearman con BH; parcial; prueba directa	ρ = 0,72 bruta pero mecánica: parcial −0,02 (p = 0,93)	No se sostiene
El entorno del barrio explica el miedo (H1)	Efectos marginales con IC por bootstrap	Atracos en el parque +13,3 pp [6,2; 17,5]	Se sostiene
A igual victimización, ellas temen más (H3)	Logit ponderado (EMV)	+18,0 pp de temor al acoso [12,9; 23,4]	Se sostiene

Del descarte al paso siguiente

Ningún descarte cerró el análisis. Cada uno cambió lo que hicimos después:

- **La serie de hurto no era comparable:** hasta 2022 la capa abierta contaba 2,28 a 2,55 veces lo que registra la Policía. Cambiamos la serie de trabajo por el SIEDCO, la confirmamos con Medicina Legal y las encuestas del DANE y la CCB, y corregimos la premisa: el hurto a personas bajó 4,2 % desde 2022, no 57,5 %. Todo lo demás se apoya en esta corrección.
- **El delito registrado no explica el miedo:** no tiene efecto en ninguna especificación (p wild = 0,92) ni mejora la predicción. Buscamos entonces en el entorno inmediato, y ahí apareció la primera hipótesis

que se sostiene: los atracos en el parque suman 13,3 pp y los conflictos vecinales 14,7 pp a la probabilidad de sentir insegura la zona.

- **Alumbrado, vías, luz e internet no explican el hurto ni la violencia:** ninguna de las 23 pruebas sobrevive a la corrección por pruebas múltiples y las más fuertes van al revés: hay más luminarias donde hay más hurto, que es el centro. Además, el 79,3 % de la violencia contra mujeres notificada a salud ocurre en la vivienda, donde la luz pública no llega. Las dejamos como estrategia exploratoria: un nulo también orienta el gasto, porque evita invertir en lo que no mueve la percepción.
- **H2 cayó al revisar nuestro propio resultado:** la primera prueba dio ρ = 0,72, pero los dos índices llevan el delito registrado. Al controlarlo, la correlación cae a −0,02 y la prueba directa entre miedo y cifra oculta da 0,16 (p = 0,51). La reportamos como no sostenida en lugar de quedarnos con la correlación alta. Con 19 localidades solo se detectan relaciones de $|\rho| \geq 0{,}60$; para probarla bien falta medir la victimización por UPL, y esa falta es la que motiva la propuesta final.

¿Se aprovechó la información?

Sí, y los rechazos lo muestran. Salvo H3, que se prueba dentro de una misma encuesta, cada hipótesis cruzó al menos dos de las 18 fuentes: registro contra registro (SCJ, SIEDCO, Medicina Legal), encuesta contra registro (Bienal, EMV y ECSC frente a SCJ) e inventarios del entorno contra delito (UAESP, IDU, IDECA, SIVIM). Lo que no se pudo probar responde a tres límites de los datos disponibles, no a un uso incompleto de ellos:

- **Unidad territorial gruesa:** el delito solo se publica por localidad, así que las pruebas territoriales tienen 19 unidades y poca potencia estadística.
- **Lo que no se denuncia casi no se mide:** la victimización no se mide por UPL ni todos los años; la ECSC no tiene 2022 ni 2024-2026.
- **Una sola foto de la percepción:** la percepción de 2025 es de un solo año, sin serie para ver cambios.

La respuesta que queda en pie. El miedo no baja porque el delito registrado bajó mucho menos de lo que mostraba la serie abierta, porque el miedo responde al entorno inmediato y no al delito registrado (H1), y porque las mujeres cargan un temor adicional a igual victimización (H3). Las dos hipótesis que se sostienen son las que se convierten en acción: parques sin atracos, mediación vecinal y rutas para las mujeres, en el orden del Índice de Brecha (Usme, Ciudad Bolívar, Bosa, Kennedy y San Cristóbal).

2. Propuesta final: un sistema unificado de registro y cruce

Este proyecto cruzó una vez 18 fuentes que hoy están separadas, con formatos, llaves territoriales y periodicidades distintas. La propuesta es que la Alcaldía Mayor de Bogotá tenga ese cruce de forma frecuente y automática, y que sume el dato que hoy no existe: lo que la gente vive y no denuncia. Responde a los tres límites que no dejaron probar todas las hipótesis.

Tres componentes

Componente	Qué hace	De dónde sale
1. Registro ciudadano (web, app y WhatsApp)	La persona reporta en pocos pasos un hurto, una agresión, un acoso o un hecho del entorno (atraco en el parque, riña), con la UPZ, la fecha y si denunció. No reemplaza la denuncia: al terminar la lleva al canal oficial (Policía, Línea 123 y las líneas de atención a mujeres).	Mide de forma continua la cifra oculta por UPZ, el dato que faltó para probar H2. El 57 % de las víctimas no denuncia y de cada 10 víctimas solo 1,8 a 3,0 llegan al registro.
2. Cruce automático	Cada mes descarga cada fuente con su fecha y huella digital, la contrasta con una fuente independiente, la	Es el pipeline del proyecto (src/pipeline.py): integra las 18

de las fuentes	une por código de localidad y UPZ y recalcula la cifra oculta, el Índice de Brecha y las tendencias. Si una serie sale del rango 0,95 a 1,10 frente a su referencia, genera una alerta antes de publicar.	fuentes y corre completo en unos 9 minutos desde un clon limpio.
3. Tablero público y de decisión	Publica cada mes el Índice de Brecha, la cifra oculta y las series validadas por localidad y UPZ, en datos abiertos (CSV y GeoJSON) y en Power BI para los equipos de planeación y las alcaldías locales.	Reutiliza el visor, el tablero de Power BI y los formatos abiertos ya entregados.

Implementación por fases

- **Meses 0 a 3:** automatizar el cruce con las fuentes abiertas actuales y publicar el primer tablero mensual con alertas de comparabilidad.
- **Meses 3 a 6:** piloto del registro ciudadano en Usme, Ciudad Bolívar y Bosa, las tres primeras del Índice de Brecha, con línea base y grupo de comparación.
- **Meses 6 a 12:** extender a las 19 localidades urbanas, conectar con los canales oficiales de denuncia y calibrar con una encuesta de victimización por UPL.

Reglas de diseño

- **Datos personales:** consentimiento explícito, nada que identifique a la persona en lo publicado y ubicación agregada por UPZ, conforme a la Ley 1581 de 2012.
- **Un reporte no es una denuncia:** es un dato estadístico, se publica agregado y se marca como autorreporte.
- **Sesgo de quien reporta:** el autorreporte no es una muestra representativa (llega más de quien usa la herramienta), así que se calibra con la encuesta por UPL antes de comparar territorios.
- **Interoperabilidad:** llaves oficiales de localidad, UPZ y UPL (IDECA), formatos abiertos y metadatos con fecha de corte y cambios de método.
- **Validar antes de publicar:** ninguna serie entra al tablero sin pasar la regla de comparabilidad.

Cómo se mide si funciona

- Reportes por UPZ y porcentaje que termina en denuncia formal.
- Cifra oculta por UPZ, actualizada cada mes.
- Días entre el corte de una fuente y su publicación ya cruzada.
- Cambios de método detectados y documentados antes de publicar.

La propuesta complementa los canales y sistemas que ya existen y no evalúa a ninguna entidad. Su valor está en conectar lo que hoy se publica por separado y en medir lo que hoy no se registra. Proyecto académico presentado al Bogotá DataJam 2026; no es un documento oficial de la Alcaldía de Bogotá.